

Atividade 1

Aplicações de Aprendizado de Máquina e Mineração de Dados

Clara Ernesto de Carvalho - 14559479

Introdução

Eu defini que usaria o AutoGluon como ferramenta da AutoML por nenhum grande motivo além de ter ouvido falar bem, e ser o primeiro que aparece na internet quando pesquisei. Além disso, separei o desenvolvimento do trabalho em 3 partes: processamento e carregamento dos dados, exploração e comparação de descobertas nos dados com o artigo, e execução dos experimentos com autoML para comparar com o artigo.

Tive dificuldade de entender todos os experimentos dos artigos, não achei onde eles seriam descritos de forma clara em lugar algum do artigo, e tive a impressão de que os experimentos foram pensados um depois do outro, sem uma predefinição inicial do que seria feito. Além disso fiquei confusa em quais experimentos foi realizando K-Fold Cross Validation, mas realizei o mesmo nos experimentos em que achei resultados no artigo. Além disso senti falta de uma tabela geral dos resultados, que não achei nem no artigo e nem no github do artigo.

Por fim, eu desenvolvi todo o projeto localmente com meu próprio ambiente de desenvolvimento preferido, e depois adaptei o notebook para não precisar de nenhum outro arquivo e funcionar no collab. O link para o collab com o notebook encontra-se aqui: https://colab.research.google.com/drive/1yV3Gf2yUR-SvSeOvKBj7yN_AmrrwMptk?usp=sharing.

Como tudo em machine learning, o notebook não é reproduzível bit a bit, então a run que fiz local e no collab diferiram nos valores, mas a diferença foi na casa do quarto dígito significativo e a ordem do ranking de melhores modelos e comparação entre experimentos se manteve a mesma, então considero que os resultados são consistentes.

Processamento e carregamento dos dados

O github relacionado ao artigo possui um csv com dados de clima, um csv com dados de clima junto dos dados de produção de arroz, e duas séries de csvs separadas por ano, uma pra dados apenas de produção de arroz da américa do sul, e outro dos maiores produtores de arroz do mundo. O único processamento que fiz foi transformar os vários arquivos csvs das séries em um só, e assim acabei utilizando o csv com dados de clima junto dos dados de produção de arroz, e os dois csvs resultantes das concatenações das séries de csvs originais.

Exploração

Eu realizei a exploração usando a biblioteca polars no csv com dados de clima e produção, para visualizar quantidade de linhas, de países, a correlação entre features e o número de outlier por feature. Todas essas análises encontraram os mesmos resultados do paper, com produção e área colhida tendo muitos outliers e uma alta correlação entre si (98%)

Logo após da exploração eu realizei um pré processamento nos dados, realizando One Hot Encoding na coluna de países e Standardization nas colunas de valores reais, mas depois descobri que o AutoGluon já faz o processamento disso sozinho, e depois vi no artigo que o treinamento acontece separado por país, então o one hot encoding não faria sentido e isso é mencionado no artigo.

Experimentos

Tentei reproduzir os experimentos do artigo com o automl, do que eu entendi dos experimentos. Para todos a principal métrica foi o MAPE, entretanto também calculei o MAE, RMSE e R2. O R2 foi a única métrica que não conhecia antes, e foi interessante usá-lo pela primeira vez. Todos os experimentos foram treinados separadamente para cada país, e os resultados agregados.

Entendi que haviam 4 experimentos a serem realizados:

1. Treino e Validação por país da américa do sul utilizando dados de treino com 3 faixas diferentes de treino para a predição dos próximos 5 anos de dados (sem clima)
2. Treino e validação da américa do sul treinando em dados anteriores a 2021 e predizendo os próximos 3 anos (sem clima)
3. Treino e validação da américa do sul treinando em dados anteriores a 2021 e predizendo os próximos 3 anos (dessa vez com clima)
4. Treino e validação nos 10 maiores produtores mundiais de arroz treinando em dados anteriores a 2021 e predizendo os próximos 3 anos (sem clima também)

Apenas no 2. e 3. realizei 5-Fold CV.

Resultados

Análise por País

Os piores resultados por país coincidem com os apontados pelo artigo, sendo os 4 piores em MAPE o Chile, Bolívia, Suriname e Paraguai no experimento com dados integrados de clima.

Além disso o volume de produção varia muito entre países, então a melhor comparação entre eles é feita com métricas relativas como o MAPE e R², já o MAE e RMSE são métricas absolutas que tendem a ser maiores para valores maiores de produção.

Por fim, diversos países ficaram com F2 negativo em vários experimentos, o que pode apontar para um overfitting já que são apenas 15 linhas por país. Talvez se fossem treinados todos juntos haveria um menor overfitting e o modelo conseguiria representar melhor os conceitos relacionados a essa predição.

Análise de Resultados Agregados

O modelo apresentou resultados melhores nos experimentos 2. e 3. com 5-Fold CV, com MAPEs de 5.80% e 8.66% nos experimentos de sem clima e com clima, respectivamente, versus 12,47% e 11,3% do paper. Além disso, foi também melhor no experimento 2. sem CV, com MAPE de 6,24% versus 13,72% do Paper. Já o experimento 3. sem CV foi um empate (10.85% versus 11.3%). Considero que o uso do AutoGluon é consistentemente melhor considerando os experimentos com CV (que são estatisticamente mais significativos) para esses experimentos.

Achei interessante que o resultado com clima com autogluon foi pior do que sem clima, especulo que os dados de clima podem ter criados um reasoning shortcut no modelo que atrapalha a generalização, ou que a maior dimensionalidade de alguma forma atrapalhou os modelos do autogluon (mas a dimensionalidade nem está grande então acho improvável). Não sei o porquê que isso também não aconteceria com os modelos do paper, então não sei o que pensar sobre.

Já para o experimento 4. o resultado do autogluon foi parecido com o resultado do XGBoost do paper, mas pior que o resultado da Regressão Linear, o que achei muito interessante já que a diversidade dos modelos no autogluon é teoricamente maior, mas talvez o modelo usado para o teste do autogluon tenha overfittado comparado ao modelo de regressão linear que possui menor dimensão VC. (verei na análise dos melhores modelos).

Para o experimento 1. foi difícil comparar pois os resultados são apenas apresentados em um gráfico e não no texto ou em tabela, mas o paper diz que o melhor intervalo é 10 anos, mas os resultados com autogluon de 15 anos foram bem melhores que os de 10 e 5 anos (7.67% vs 10.36% e 11.13%).

Análise dos Rankings de modelos

Em todos os experimentos alguns poucos modelos ficaram no top1, sendo eles o LightGBM, NeuralNetTorch, WeightedEnsembleL2 e LightGBMLarge

Até onde entendo o LightGBM e LightGBMLarge são ambos modelos de gradient boosting com árvores que normalmente funcionam bem com dados tabulares, o que faz bastante sentido de terem ido bem. Já o NeuralNetTorch foi uma surpresa para mim já que esperava que não fosse ter um resultado tão bom, já que a maioria dos experimentos possui pouquíssimos dados de entrada e não esperava que a rede neural fosse convergir. Já o WeightedEnsembleL2 foi bem em todos os experimentos (o melhor ou empatado com o melhor), pelo que entendi da documentação, é um meta-modelo que usa os outros modelos como base e faz uma votação ponderada com algoritmo guloso, em geral ensembles são bons em generalização então faz sentido ele ter sido bom em um cenário com poucos dados, mas eu precisaria entender mais de como o autogluon funciona para conseguir produzir alguma análise mais significativa dele.

Já os outros modelos foram consistentemente piores, talvez pelo volume de dados, talvez pela baixa capacidade de generalização, talvez pelos dois. Senti curiosidade de testar modelos do paper com tuning de hiperparâmetro, o que é algo que o paper não faz, e fica de trabalho futuro.